

Análisis Factorial: Psych

Oscar Elí Bonilla Morales

2022-05-22

Para este ejercicio necesitaremos la ayuda de la paquetería “psych”, paquetería la cual nos permitirá acceder a los datos los cuales utilizaremos.

De igual manera se instalarán y cargarán mas paqueterías las cuales serán utilizadas para los análisis.

```
install.packages("psych")
```

```
library(psych)
```

```
library(polycor)
```

```
install.packages("ggcorrplot")
```

```
library(ggcorrplot)
```

Extracción de datos

```
x <- bfi
```

Exploración de matriz

```
dim(x)
```

```
## [1] 2800 28
```

Tipos de variables

```
str(x)
```

```
## 'data.frame': 2800 obs. of 28 variables:
## $ A1 : int 2 2 5 4 2 6 2 4 4 2 ...
## $ A2 : int 4 4 4 4 3 6 5 3 3 5 ...
## $ A3 : int 3 5 5 6 3 5 5 1 6 6 ...
## $ A4 : int 4 2 4 5 4 6 3 5 3 6 ...
## $ A5 : int 4 5 4 5 5 5 5 1 3 5 ...
## $ C1 : int 2 5 4 4 4 6 5 3 6 6 ...
## $ C2 : int 3 4 5 4 4 6 4 2 6 5 ...
## $ C3 : int 3 4 4 3 5 6 4 4 3 6 ...
## $ C4 : int 4 3 2 5 3 1 2 2 4 2 ...
## $ C5 : int 4 4 5 5 2 3 3 4 5 1 ...
## $ E1 : int 3 1 2 5 2 2 4 3 5 2 ...
## $ E2 : int 3 1 4 3 2 1 3 6 3 2 ...
```

```
## $ E3      : int  3 6 4 4 5 6 4 4 NA 4 ...
## $ E4      : int  4 4 4 4 4 5 5 2 4 5 ...
## $ E5      : int  4 3 5 4 5 6 5 1 3 5 ...
## $ N1      : int  3 3 4 2 2 3 1 6 5 5 ...
## $ N2      : int  4 3 5 5 3 5 2 3 5 5 ...
## $ N3      : int  2 3 4 2 4 2 2 2 5 ...
## $ N4      : int  2 5 2 4 4 2 1 6 3 2 ...
## $ N5      : int  3 5 3 1 3 3 1 4 3 4 ...
## $ O1      : int  3 4 4 3 3 4 5 3 6 5 ...
## $ O2      : int  6 2 2 3 3 3 2 2 6 1 ...
## $ O3      : int  3 4 5 4 4 5 5 4 6 5 ...
## $ O4      : int  4 3 5 3 3 6 6 5 6 5 ...
## $ O5      : int  3 3 2 5 3 1 1 3 1 2 ...
## $ gender   : int  1 2 2 2 1 2 1 1 1 2 ...
## $ education: int  NA NA NA NA NA 3 NA 2 1 NA ...
## $ age      : int  16 18 17 17 17 21 18 19 19 17 ...
```

Nombre de las variables

```
colnames(x)
```

```
## [1] "A1"      "A2"      "A3"      "A4"      "A5"      "C1"
## [7] "C2"      "C3"      "C4"      "C5"      "E1"      "E2"
## [13] "E3"      "E4"      "E5"      "N1"      "N2"      "N3"
## [19] "N4"      "N5"      "O1"      "O2"      "O3"      "O4"
## [25] "O5"      "gender"   "education" "age"
```

Creación de una matriz de datos donde se incluyan las variables 1 a la 25, solo se considerarán las primeras 200 observaciones.

```
x1 <- bfi[1:200, 1:25]
head(x1)
```


```
##      A1 A2 A3 A4 A5 C1 C2 C3 C4 C5 E1 E2 E3 E4 E5 N1 N2 N3 N4 N5 O1 O2 O3 O4
## 61617  2  4  3  4  4  2  3  3  4  4  3  3  3  4  4  3  4  2  2  3  3  6  3  4
## 61618  2  4  5  2  5  5  4  4  3  4  1  1  6  4  3  3  3  3  5  5  4  2  4  3
## 61620  5  4  5  4  4  4  5  4  2  5  2  4  4  4  5  4  5  4  2  3  4  2  5  5
## 61621  4  4  6  5  5  4  4  3  5  5  5  3  4  4  4  2  5  2  4  1  3  3  4  3
## 61622  2  3  3  4  5  4  4  5  3  2  2  2  5  4  5  2  3  4  4  3  3  3  4  3
## 61623  6  6  5  6  5  6  6  6  1  3  2  1  6  5  6  3  5  2  2  3  4  3  5  6
##      O5
## 61617  3
## 61618  3
## 61620  2
## 61621  5
## 61622  3
## 61623  1
```

Matriz de correlaciones

```
R <- hetcor(x1)$correlations
```

Gráfico de correlaciones

```
ggcorrplot(R, type = "lower", hc.order = TRUE)
```



Factorización de la matriz de correlaciones

Utilizamos la prueba de esfericidad de Barlett.

```
p_Barlett <- corstest.bartlett(R)
```

Visualización de p-valor

```
p_Barlett$p.value
```

```
## [1] 5.931663e-60
```

- Ho: Las variables están correlacionadas
- Ha: Las variables no están correlacionadas.

No se rechaza Ho ya que las variables están correlacionadas.

Criterio Kaiser-Mayer

Nos permite identificar si los datos que serán analizados serán adecuados para un análisis factorial.

- 0,00 a 0.49 No adecuados
- 0.50 A 0.59 Poco adecuados

- 0.60 a 0.69 Aceptables
- 0.70 a 0.89 Buenos
- 0.80 a 1.00 Excelentes

KMO(R)

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = R)
## Overall MSA = 0.76
## MSA for each item =
##   A1  A2  A3  A4  A5  C1  C2  C3  C4  C5  E1  E2  E3  E4  E5  N1
## 0.66 0.77 0.69 0.73 0.75 0.74 0.79 0.76 0.76 0.74 0.80 0.81 0.79 0.81 0.83 0.70
##   N2  N3  N4  N5  O1  O2  O3  O4  O5
## 0.67 0.82 0.79 0.82 0.79 0.65 0.81 0.62 0.77
```

Una vez observado el valor arrojado por este análisis podemos concluir que nuestros datos son adecuados a un nivel “Bueno” para nuestro análisis factorial

Extracción de factores

- minres: mínim residuo
- mle: max Verosimilitud
- paf: ejes principales
- alpha: alfa
- minchi: minimos cuadrados
- minrak: minimo rango

```
modelo1 <- fa(R, nfactor = 3, rotate = "none", fm = "mle")
```

```
modelo2 <- fa(R, nfactor = 3, rotate = "none", fm = "minres")
```

Extracción del resultado de las comunialidades

Aqui se encuentra la proporción de la varianza explicada. Se interpreta de tal forma que números cercanos a 1, el factor explicará mejor la variable.

```
C1 <- sort(modelo1$communality, decreasing = TRUE)
```

```
C2 <- sort(modelo2$communality, decreasing = TRUE)
```

```
head(cbind(C1, C2))
```

```
##           C1           C2
## N1 0.7576920 0.6809294
## E2 0.6802809 0.6564523
## N2 0.6797943 0.5866483
## E1 0.5219674 0.5394762
## N3 0.5198285 0.4942059
## N4 0.4839516 0.4744005
```

Recordemos que los números cercanos a 1, significarán que el factor explica a la varibale, por lo que para nuestra variable 1 esta muy bien explicada.

Extracción de unidades

La unidad es el cuadrado del coeficiente del factor único, y se expresa como la porción de la varianza explicada por el factor único. Es decir, no puede ser explicada por otros factores.

```
u1 <- sort(modelo1$uniquenesses, decreasing = TRUE)
```

```
u2 <- sort(modelo2$uniquenesses, decreasing = TRUE)
```


```
head(cbind(u1,u2))
```

```
##      u1      u2
## 02 0.9460554 0.9293483
## A4 0.8928892 0.8908844
## A1 0.8607240 0.8822080
## 05 0.8533481 0.8272041
## C5 0.8136600 0.7931685
## 01 0.7986908 0.7904667
```

Esta pequeña tablasm muestra las variables con valores cercanos a uno, podemos decir que estas son las variables mejor explicadas entre los 2 modelos.

Generación de screeplot

```
scree(R)
```



En este gráfico se representan tanto los componentes principales (puntos negros), como los factores a través del análisis factorial (puntos blancos), si decidimos proceder con un análisis factorial solo condieraremos 5 factores, como se puede observar en el gráfico, por otro lado, si se opta por realizarlo por componentes, utilizaremos 6 componentes.

Rotación de la matriz


```
install.packages("GPArotation")
```

```
library(GPArotation)
```




```
rot <- c("None", "Varimax", "Quartimax", "Promax")
bi_mod <- function(tipo){
  biplot.psych(fa(x1, nfactors = 2,
    fm= "minres", rotate = tipo),
    main = paste("Biplot con rotación", tipo),
    col = c(2,3,4), pch = c(21,18), group = bfi[, "gender"])
}
```

```
sapply(rot, bi_mod)
```

```
## Specified rotation not found, rotate='none' used
```



```
## Specified rotation not found, rotate='none' used
```



```
## $None
## NULL
##
## $Varimax
## NULL
```


```
##
## $Quartimax
## NULL
##
## $Promax
## NULL
```

Interpretación

```
modelo_varimax <- fa(R, nfactors = 5,
  rotate = "varimax",
  fm = "minres")
```

```
fa.diagram(modelo_varimax)
```

Factor Analysis



Vizualización de la matriz de carga rotada

```
print(modelo_varimax$loadings, cut= 0)
```

```
##
## Loadings:
##      MR1    MR2    MR4    MR3    MR5
## A1  0.234  0.106 -0.422 -0.072 -0.092
## A2  0.112 -0.032  0.653  0.190  0.113
## A3  0.198  0.066  0.744  0.051  0.169
## A4  0.163 -0.048  0.413  0.137 -0.142
```



```

## A5  0.328 -0.154  0.692 -0.009  0.115
## C1  0.054  0.089  0.140  0.634  0.287
## C2  0.052  0.174  0.114  0.690  0.050
## C3  0.032  0.018  0.076  0.642  0.016
## C4 -0.058  0.087 -0.090 -0.559 -0.159
## C5 -0.241  0.228 -0.040 -0.459  0.014
## E1 -0.691 -0.006 -0.066 -0.084 -0.017
## E2 -0.713  0.345 -0.138 -0.133 -0.025
## E3  0.546  0.003  0.157 -0.008  0.221
## E4  0.522 -0.027  0.416  0.167  0.048
## E5  0.588 -0.009  0.148  0.308  0.159
## N1  0.131  0.802 -0.150 -0.074 -0.133
## N2  0.088  0.800 -0.151 -0.038 -0.008
## N3 -0.183  0.701  0.005  0.037 -0.087
## N4 -0.513  0.491 -0.006  0.004  0.034
## N5 -0.274  0.571  0.059  0.096 -0.082
## O1  0.203 -0.107  0.148  0.076  0.535
## O2 -0.099  0.096  0.144 -0.191 -0.330
## O3  0.326 -0.159  0.034  0.062  0.680
## O4 -0.240  0.122  0.169  0.105  0.548
## O5 -0.004  0.061 -0.074 -0.077 -0.636
##
##              MR1   MR2   MR4   MR3   MR5
## SS loadings    2.823 2.667 2.223 2.103 1.867
## Proportion Var 0.113 0.107 0.089 0.084 0.075
## Cumulative Var 0.113 0.220 0.309 0.393 0.467

```

Una vez realizado esto, podemos comentar que las líneas rojas en el diagrama de árbol son las cargas negativas y las líneas negras son cargas positivas, de igual manera, viendo los resultados en la función “loadings” podemos ver como es que numericamente están agrupados nuestros factores.